Week10 作業：PCA 與 K-means 分群分析

第4組：廖晢勛（B1229009）、姚睿、林敬棠、黃柏瑞
資料：students_200.csv（200 位學生的 chinese、english 成績）

一、分析步驟與過程說明

1. **讀取與標準化**：讀入 students_200.csv，只取 chinese、english 兩欄（student_id、true_cluster 不參與分群），以 StandardScaler 標準化，使兩科在相同尺度上計算距離。
2. **原始資料分群**：對標準化後的原始 2 維資料使用 KMeans(n_clusters=3, n_init=10, random_state=42) 分群，計算 silhouette score。
3. **PCA 降維**：對標準化資料做 PCA，計算各主成分的特徵值、貢獻率與累積貢獻率，並畫出 Scree Plot。
4. **嘗試不同維度**：分別取 n_components = 1、2，各自重新用 KMeans(n=3) 分群並計算 silhouette score。
   ※ 題目建議可嘗試 1、2、3 維；但本資料只有 2 個特徵，PCA 的主成分數上限為 min(樣本數, 特徵數) = 2，因此無法降到 3 維，只比較 1 維與 2 維。
5. **比較並選出最適維度**：以 silhouette score 最高者為最佳降維維度。

二、使用 AI 工具協助的截圖

使用 AI 工具：Claude Code（Claude Pro），在終端機中下指令請 AI 撰寫並執行程式。

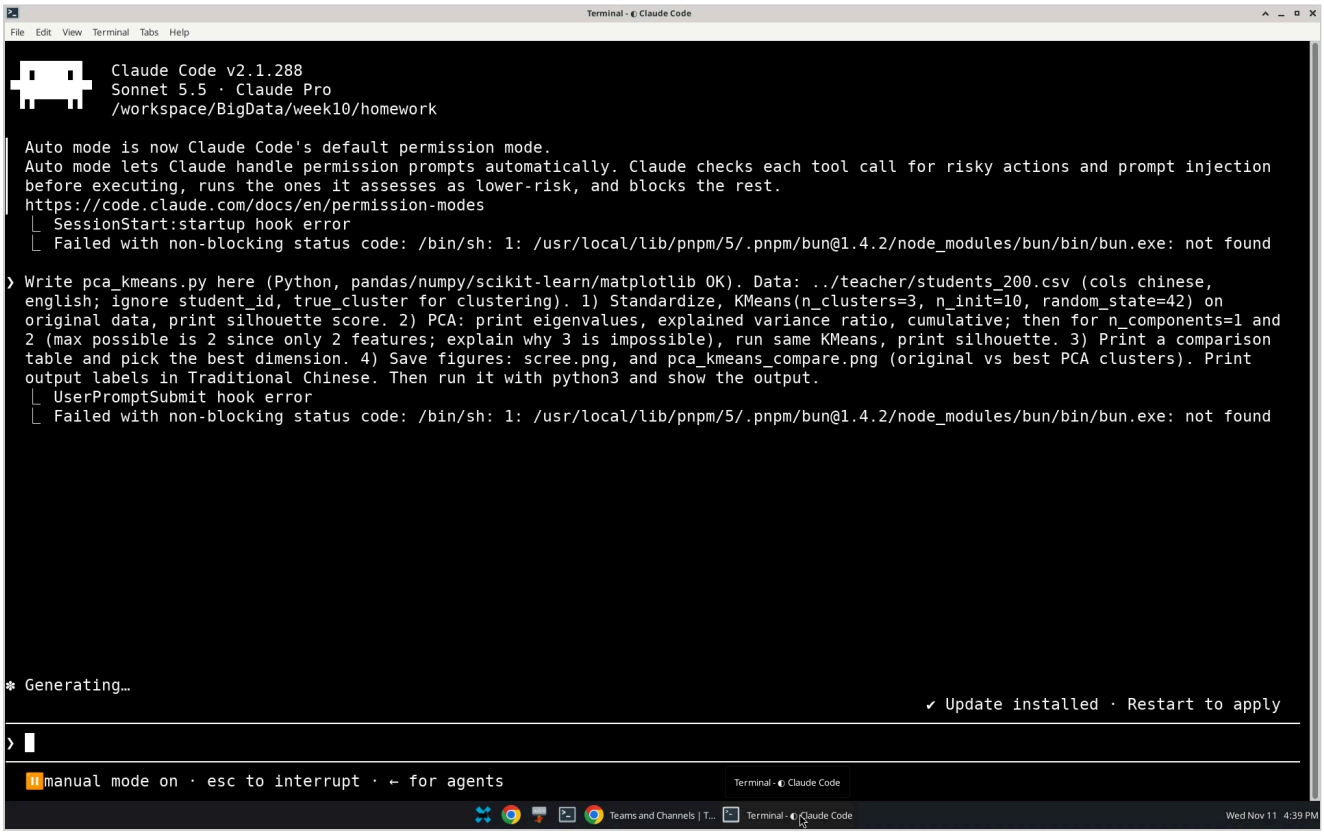


圖 1：向 Claude Code 輸入分析需求，AI 開始產生程式

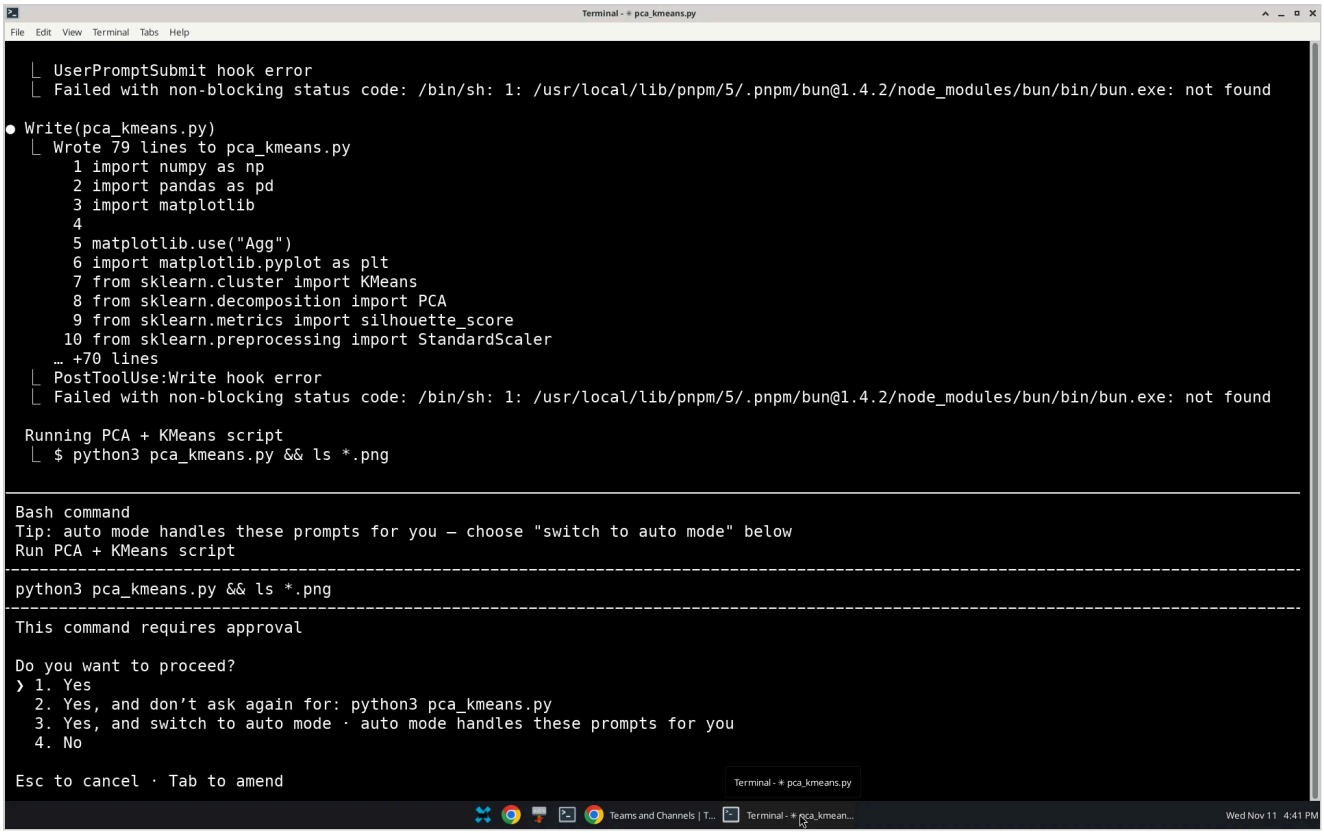


圖 2：AI 撰寫 pca_kmeans.py 並請求執行權限

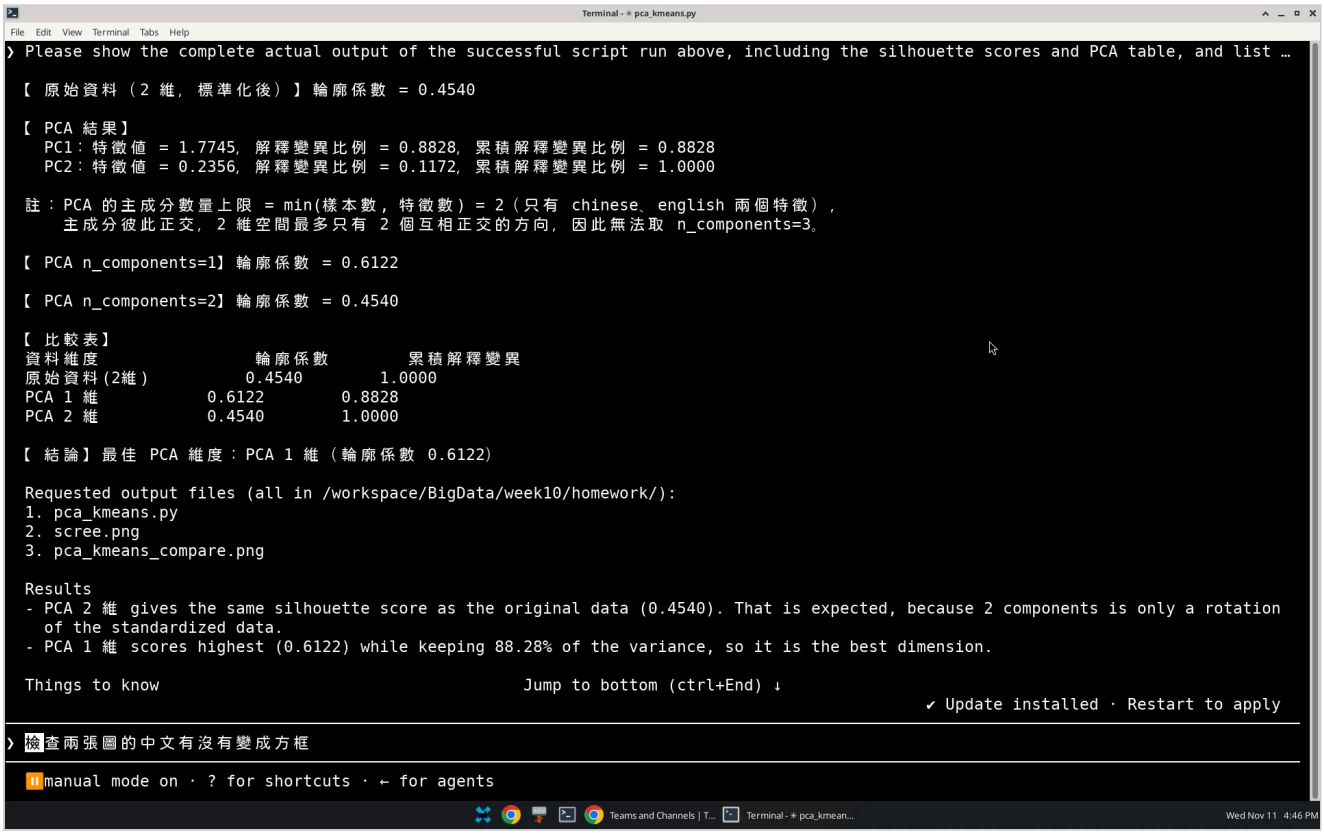


圖 3：AI 執行程式後的輸出（特徵值、貢獻率、silhouette score、比較表）

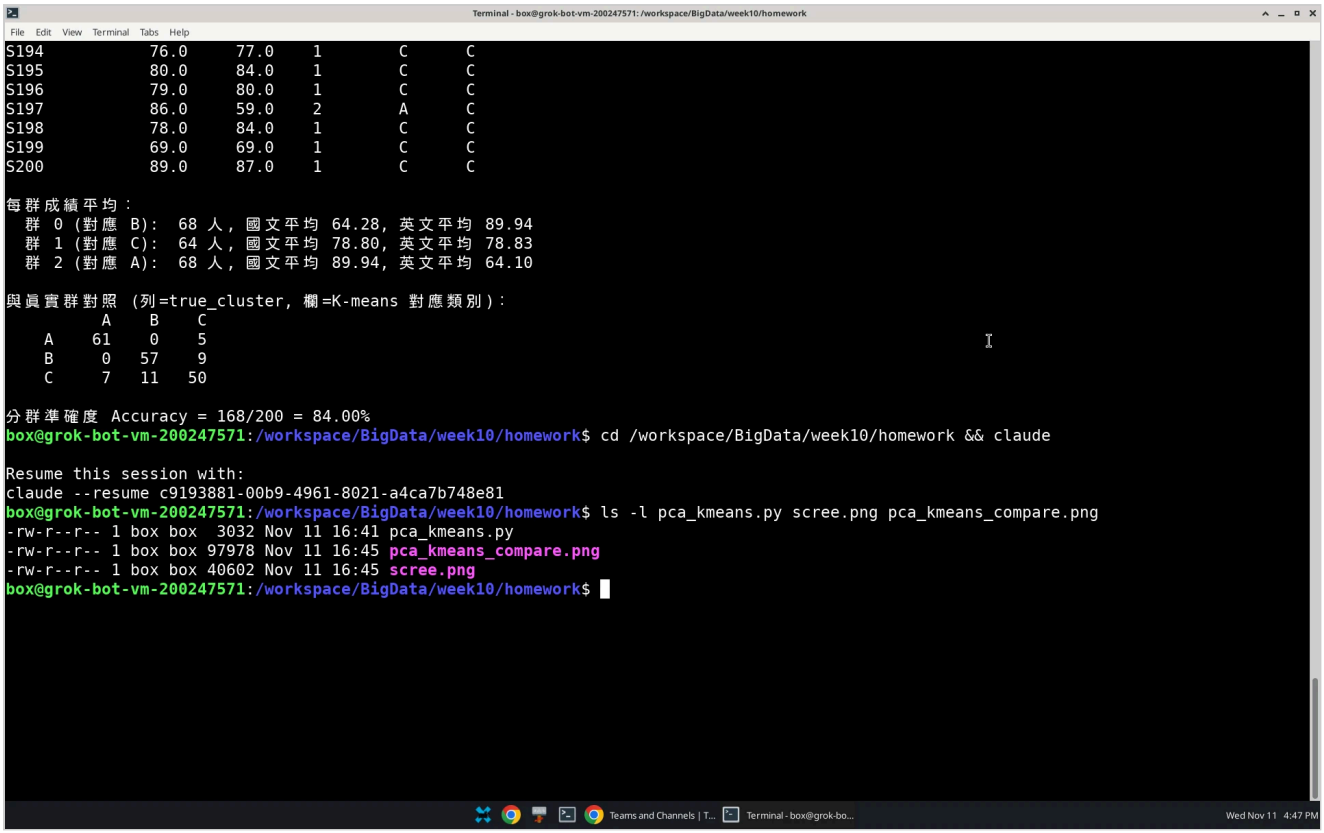


圖 4：確認輸出檔案

三、程式碼

完整程式碼另附檔案 **pca_kmeans.py**（執行：`python3 pca_kmeans.py`，需與 students_200.csv 同一份資料）。分群圖中每一群以虛線圈標示：圓心為群中心（紅色 ×），半徑為群內離中心最遠的距離。

四、輸出結果

```
【原始資料（2 維，標準化後)】輪廓係數 = 0.4540

【PCA 結果】
  PC1：特徵值 = 1.7745，解釋變異比例 = 0.8828，累積解釋變異比例 = 0.8828
  PC2：特徵值 = 0.2356，解釋變異比例 = 0.1172，累積解釋變異比例 = 1.0000

註：PCA 的主成分數量上限 = min(樣本數, 特徵數) = 2（只有 chinese、english 兩個特徵），
    主成分彼此正交，2 維空間最多只有 2 個互相正交的方向，因此無法取 n_components=3。

【PCA n_components=1】輪廓係數 = 0.6122

【PCA n_components=2】輪廓係數 = 0.4540

【比較表】
資料維度                  輪廓係數        累積解釋變異
原始資料(2維)          0.4540       1.0000
PCA 1 維           0.6122       0.8828
PCA 2 維           0.4540       1.0000
```

```
【結論】最佳 PCA 維度：PCA 1 維（輪廓係數 0.6122）
```

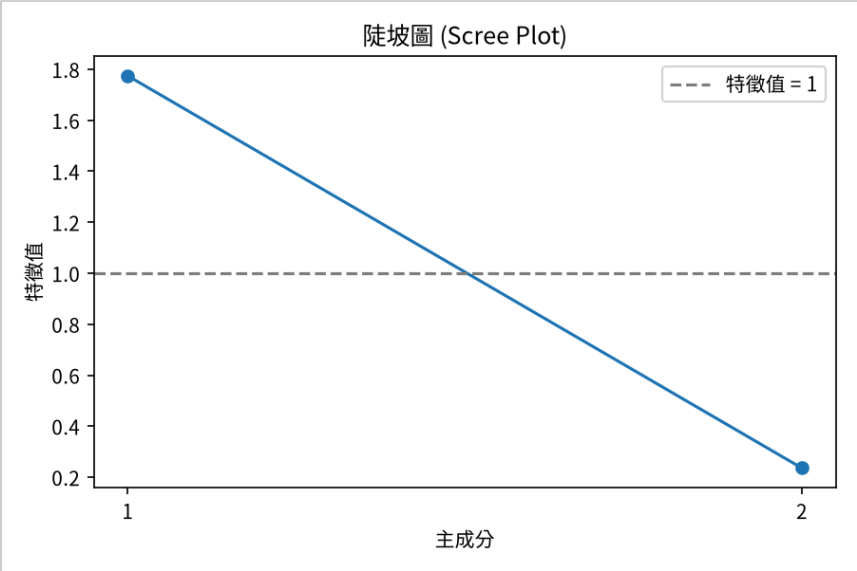


圖 5：Scree Plot（PC1 特徵值 1.7745，貢獻率 88.28%，已超過 80%）

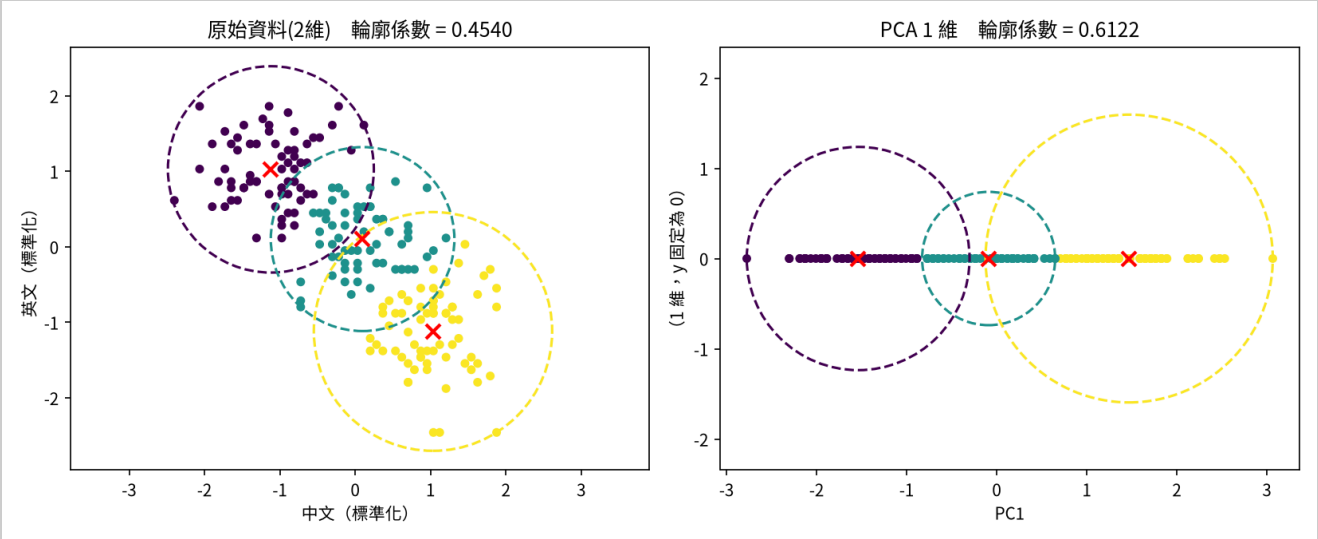


圖 6：原始資料（2 維）與 PCA 1 維的 K-means 分群結果

五、降維前後的 silhouette score 比較

資料維度	Silhouette score	累積解釋變異
原始資料（2 維，標準化）	0.4540	100.00%
PCA 1 維	**0.6122**	88.28%
PCA 2 維	0.4540	100.00%

結論：最適降維維度為 PCA 1 維（silhouette score 0.6122，高於原始資料的 0.4540）。

- PC1 一個主成分就保留了 88.28% 的資料變異，超過 80% 的門檻，足以代表主要資料結構。

- PCA 2 維只是把標準化後的資料做旋轉，點與點之間的距離不變，所以分群結果與 silhouette score 都和原始資料相同（0.4540）。
- 降到 1 維後，去掉了變異較小的 PC2 方向（多為雜訊），各群在 PC1 上分得更開、群內更緊密，因此 silhouette score 提高到 0.6122。