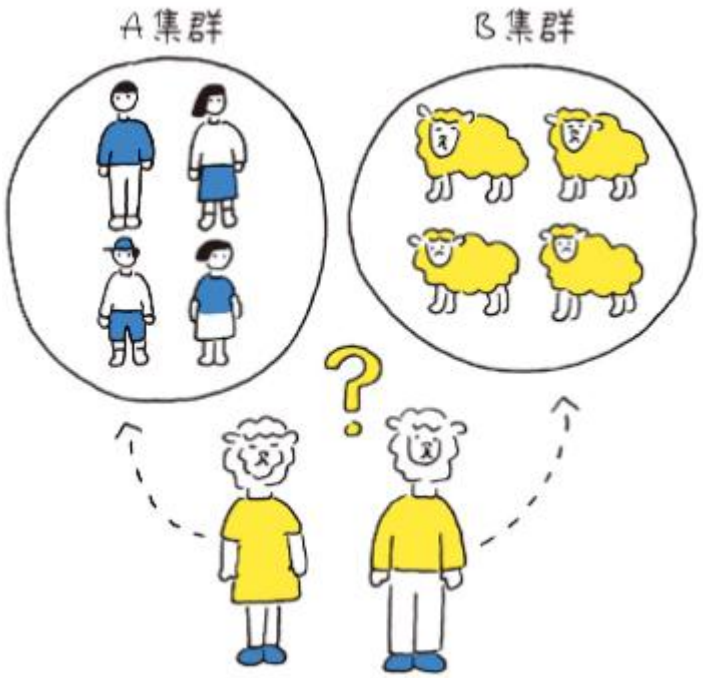



# 分類相似者

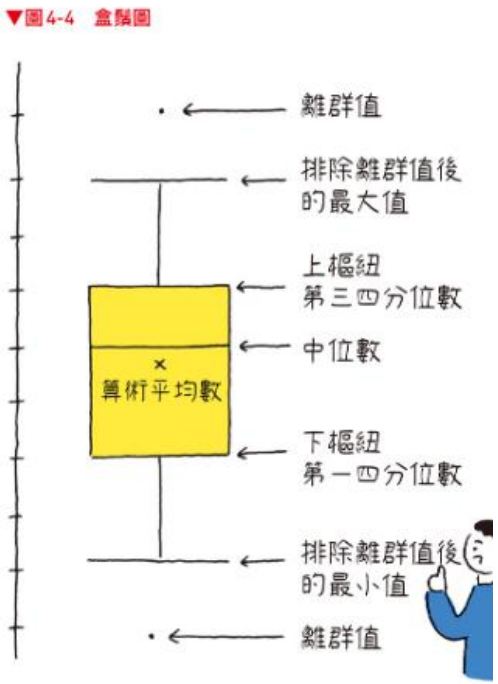
A. 群集分析 (Cluster analysis)

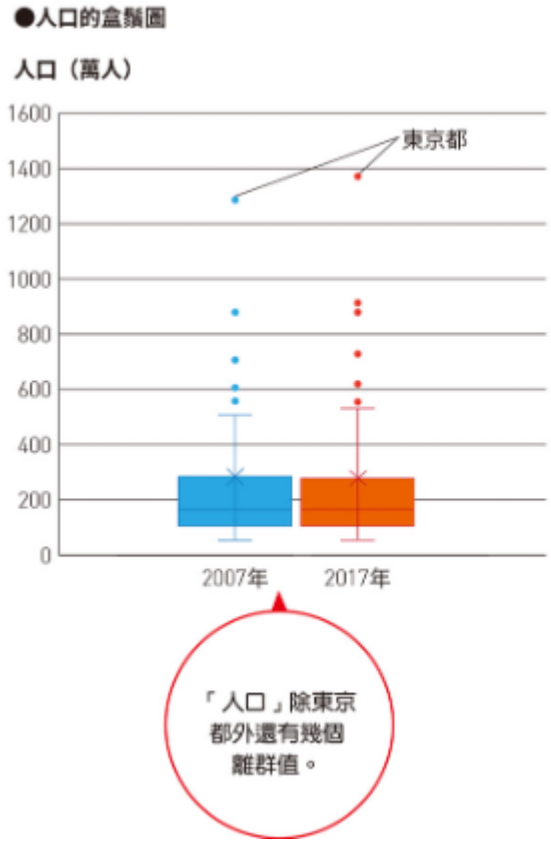
B. 主成分分析 (Principal components analysis, PCA)

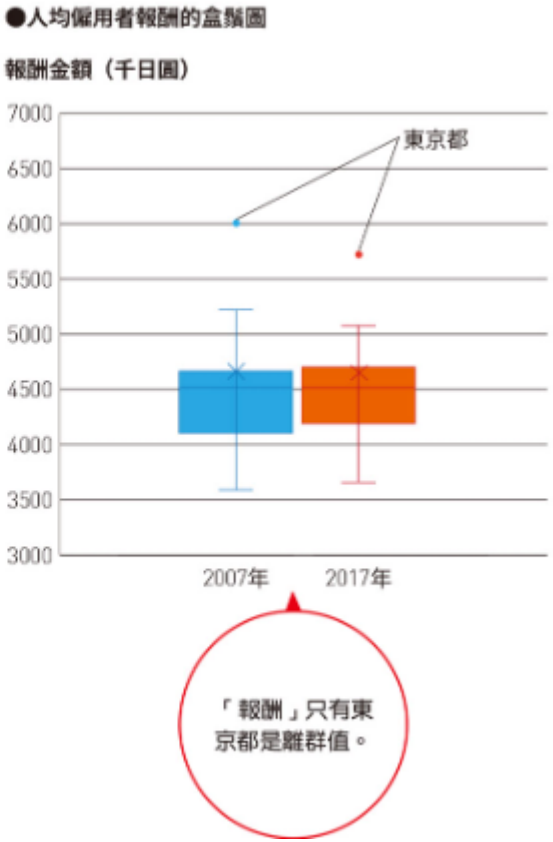
C. 對應分析 (Correspondence analysis)

# 前言

從單變數的結果來分類



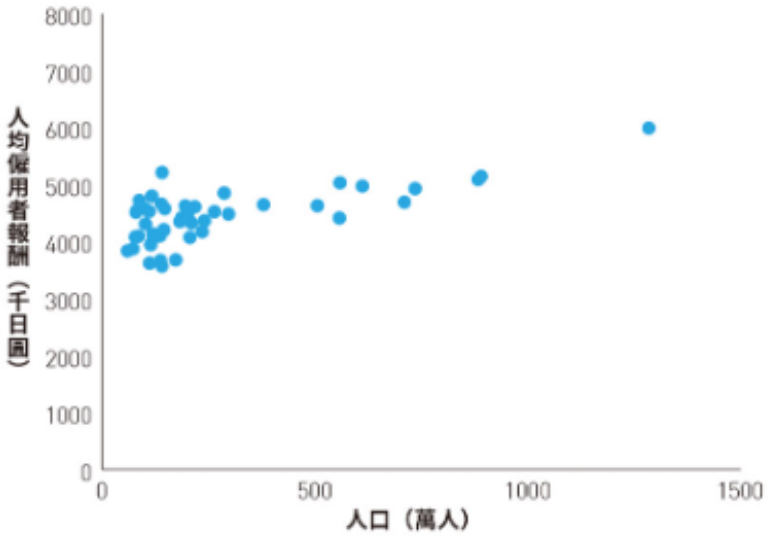



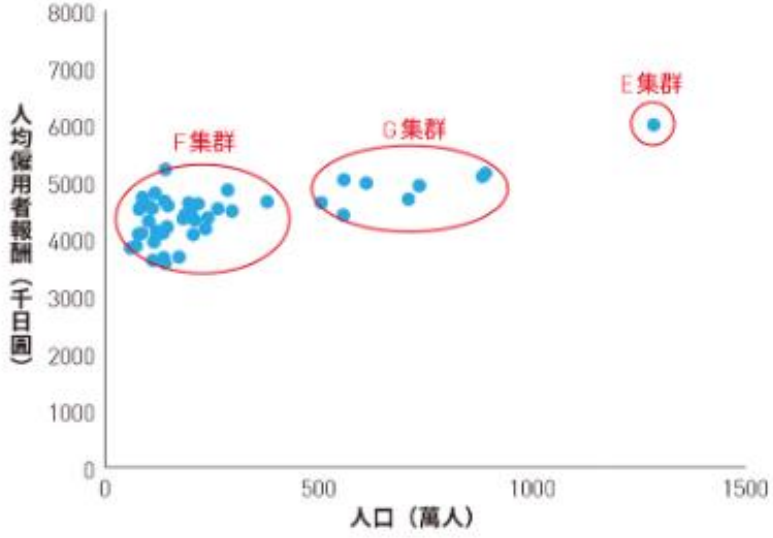
# 前言

- 從二個變數的結果來分類

▼圖 4-6　「人口」與「人均僱用者報酬」的散布圖




▼圖 4-8　將集群分析結果反映在圖 4-6 的散布圖上並加以分類

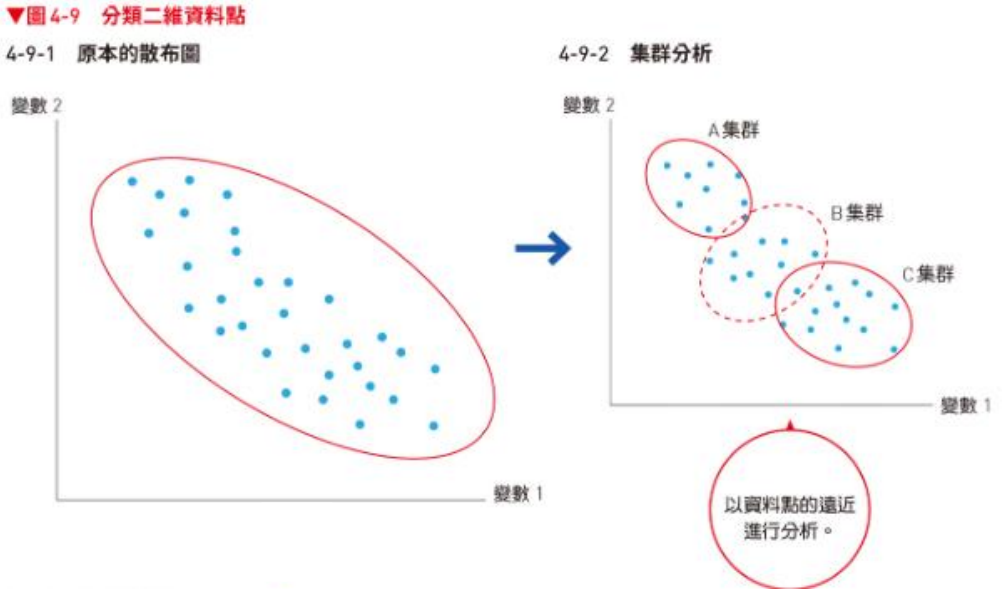


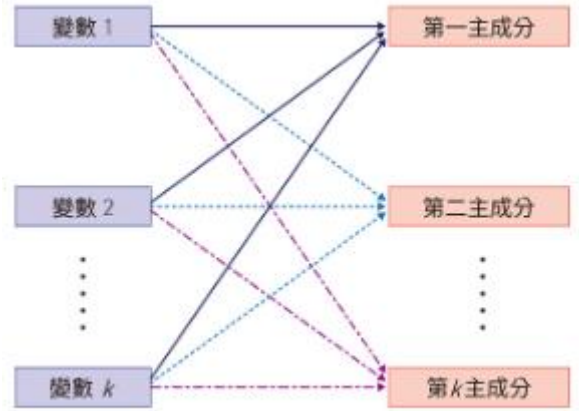
# B. 主成分分析 (Principal components analysis, PCA)

- 多維資料轉換成少數幾個綜合變數（主成分），以利後續的分群或分類分析

- 相互關聯的變數，例如學生的多項學習表現指標、顧客的消費行為變數等。若要直接以多變數進行分群（例如K-means、階層式分群），會因變數之間的共線性與維度過高而使分析結果不易解釋

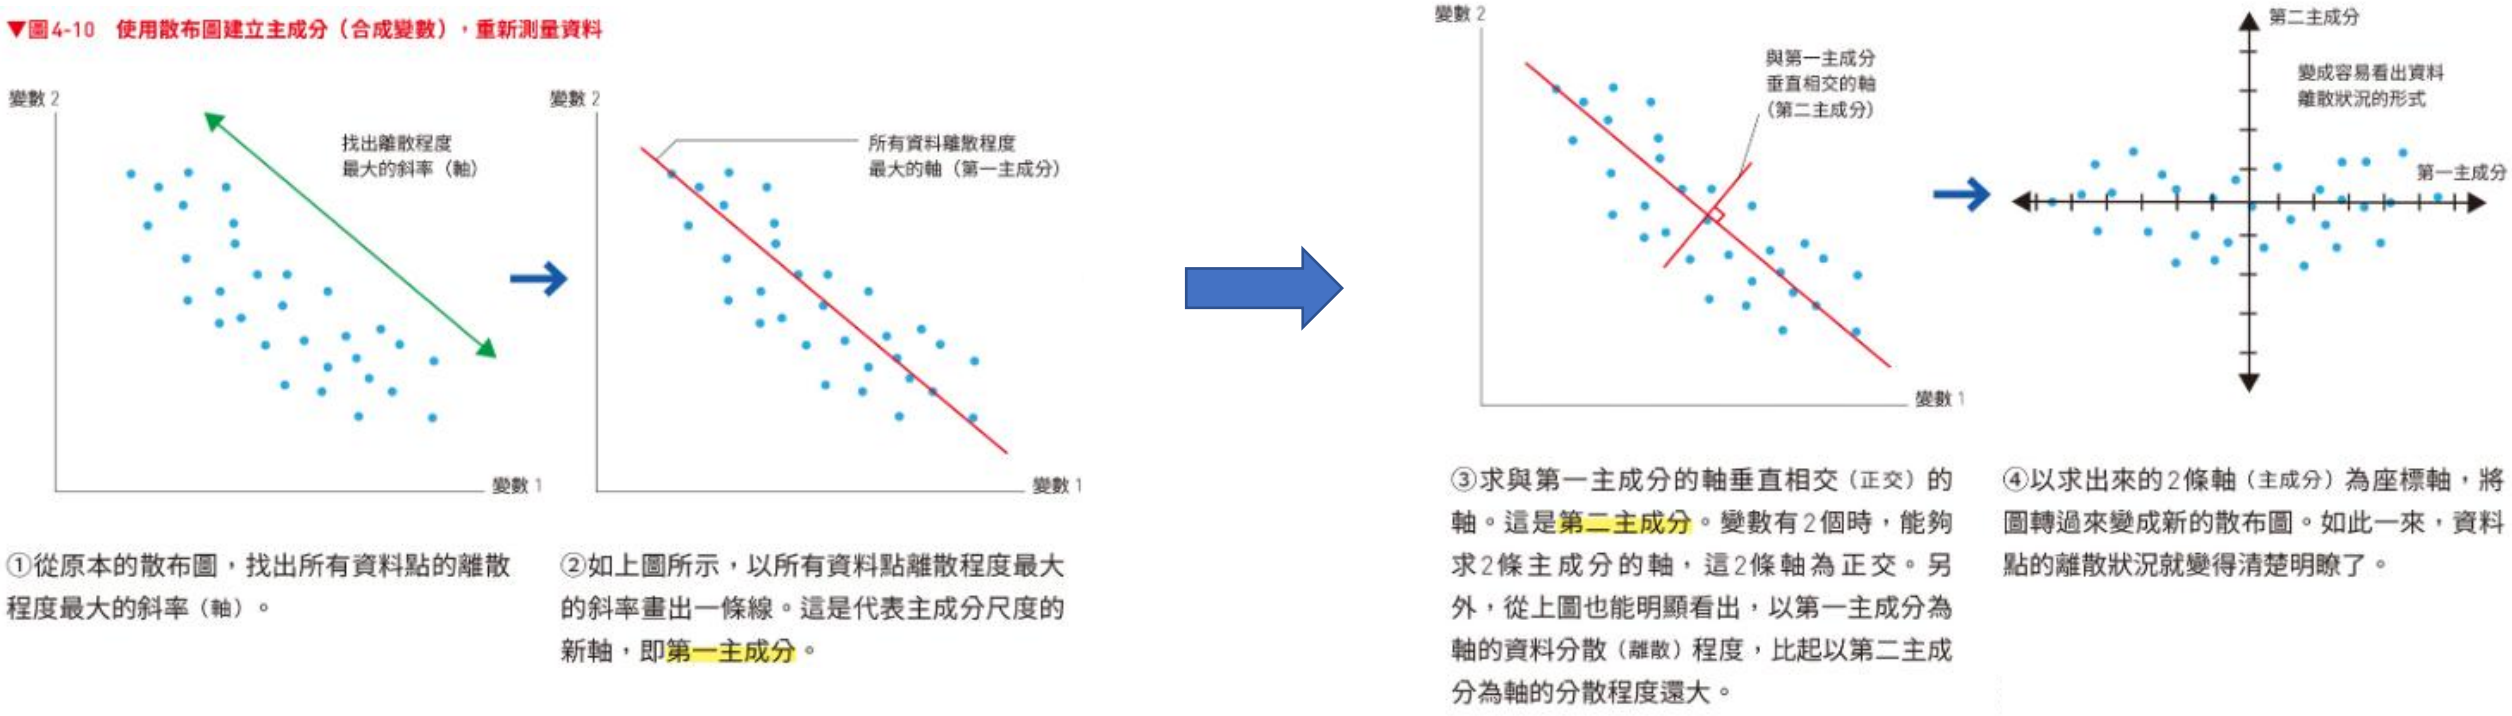
- 先透過 **主成分分析（Principal Component Analysis, PCA）**，把多個相關變數合併為較少數的新變數，這些新變數稱為 **主成分（Principal Components）**



# B. 主成分分析 (Principal components analysis, PCA)

- PCA 是一種 **維度縮減（Dimension Reduction）** 技術
  - 若原始資料有20個變數，經主成分分析後，可能可由2~3個主成分解釋大部分變異。
  - 每個主成分都是多個原變數的**線性組合**




①從原本的散布圖，找出所有資料點的離散程度最大的斜率（軸）。

②如上圖所示，以所有資料點離散程度最大的斜率畫出一條線。這是代表主成分尺度的新軸，即第一主成分。

③求與第一主成分的軸垂直相交（正交）的軸。這是第二主成分。變數有2個時，能夠求2條主成分的軸，這2條軸為正交。另外，從上圖也能明顯看出，以第一主成分為軸的資料分散（離散）程度，比起以第二主成分為軸的分散程度還大。

④以求出來的2條軸（主成分）為座標軸，將圖轉過來變成新的散布圖。如此一來，資料點的離散狀況就變得清楚明瞭了。

# B. 主成分分析 (Principal components analysis, PCA)

- 依重要程度排序找出來的**主成分**

  在進行主成分分析（PCA）時，可求得的主成分數量上限為「原始變數的個數」

  每一個主成分都是根據資料中「變異最大」的方向而建立，並且依其解釋的變異大小進行排序：

  - **第一主成分（PC1）**：說明資料中變異最大的方向（最重要）
  - **第二主成分（PC2）**：說明剩餘變異中次大的方向（次重要）
  - 依此類推，主成分的數量越多，能解釋的資料變異也越完整，但每一個主成分的貢獻度會逐漸下降

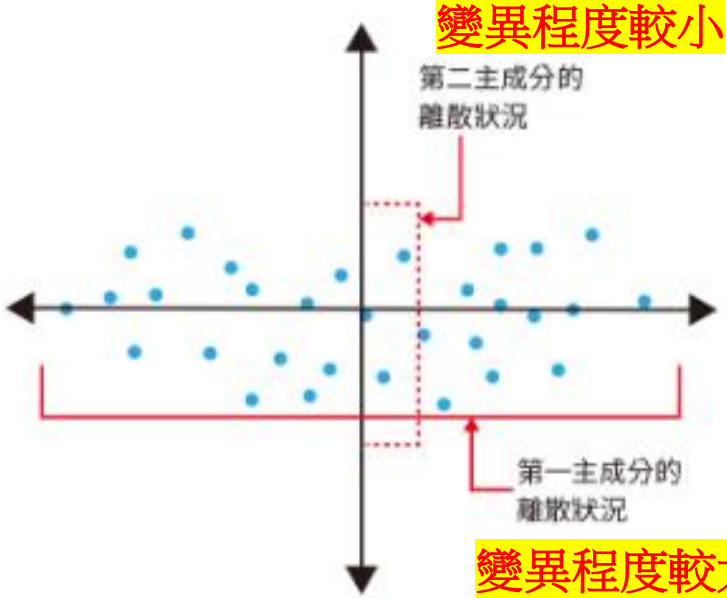
- 主成分的**變異程度** 代表其重要性

  主成分的變異越大，代表該主成分能捕捉越多的資料結構資訊

  主成分變異較小，表示該方向的資訊較少

▼圖4-11　主成分順序的意義

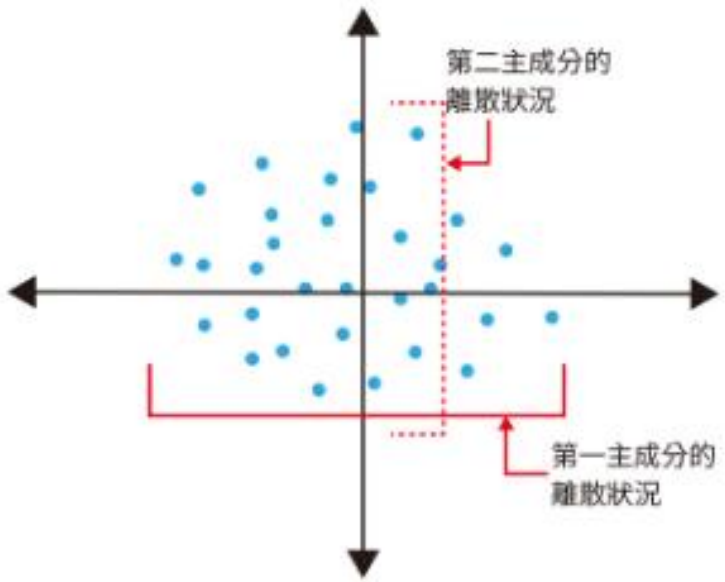
4-11-1　第一主成分的構成比很大時




變異程度較小

變異程度較大

4-11-2　第一主成分與第二主成分的構成比差不多時




二個主成分的
變異程度接近

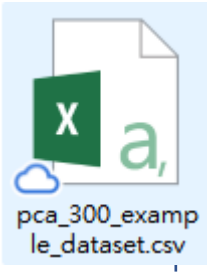
▼圖4-12　變異數構成比

$$\text{變異數構成比（\%）（貢獻率）} = \frac{\text{各主成分的變異數}}{\text{所有主成分的變異數}} \times 100$$

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

n個資料

p個特徵




計算變數間的共變異關係

$$S = \frac{1}{n-1} X^\top X$$

計算特徵值 (Eigenvalue)

$$Sv_i = \lambda_i v_i$$

- vi：第 i 個 **特徵向量（Eigenvector）**，對應第 i 個主成分的方向
- λi ：**特徵值（Eigenvalue）**，表示該主成分的**資料變異量**
- 特徵值 **越大** → 該主成分能解釋的資料變異越多
- 特徵值 **的總和** → 資料中全部變數的總變異

$$\sum_{i=1}^{p} \lambda_i = \text{總變異}$$

每一個主成分的**貢獻率**（Explained Variance Ratio）：

$$\text{貢獻率}_i = \frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j}$$

$$\text{累積貢獻率} = \sum_{i=1}^{k} \text{貢獻率}_i$$

若前 k 個主成分的累積貢獻率達 80% 以上，
即可視為足夠保留主要資料結構

```python
import numpy as np
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
import pandas as pd

# 假設 X 為原始資料矩陣 (n x p)
X = pd.read_csv("pca_300_example_dataset.csv").values  #X 從CSV載入

#np.random.seed(42) #X 隨機產生
#X = np.random.rand(600, 6)  # 600 筆樣本、6 個變數
X_std = StandardScaler().fit_transform(X)  # 標準化

# 輸出標準化後的資料內容
print("=== 標準化後的資料 X_std ===")
print(pd.DataFrame(X_std, columns=[f"變數{i+1}" for i in
range(X_std.shape[1])]))

pca = PCA()
pca.fit(X_std)

eigenvalues = pca.explained_variance_          # 各主成分的特徵值
variance_ratio = pca.explained_variance_ratio_ # 各主成分貢獻率
cumulative = np.cumsum(variance_ratio)

result = pd.DataFrame({
    "主成分": [f"PC{i+1}" for i in range(len(eigenvalues))],
    "特徵值 (變異量)": eigenvalues,
    "貢獻率": variance_ratio,
    "累積貢獻率": cumulative
})

print("\n=== PCA 結果 ===")
print(result)
```

```python
import matplotlib.pyplot as plt

plt.plot(range(1, len(eigenvalues)+1), eigenvalues, marker='o')
plt.xlabel('PC')
plt.ylabel('eigenvalues')
plt.title('Scree Plot')
plt.show()
```

# kmean vs PCA_kmean.ipynb

**Silhouette score（輪廓係數）**：評估 **分群品質** 的指標
衡量「每個樣本在自己的群內有多緊密、與其他群有多遠」

資料集中樣本 i：

- a(i)：樣本 iii 與 **同群其他樣本** 的平均距離（群內距離）
- b(i)：樣本 iii 與 **最近的其他群** 中樣本的平均距離（最近外群距離）

該樣本的 silhouette 值為：

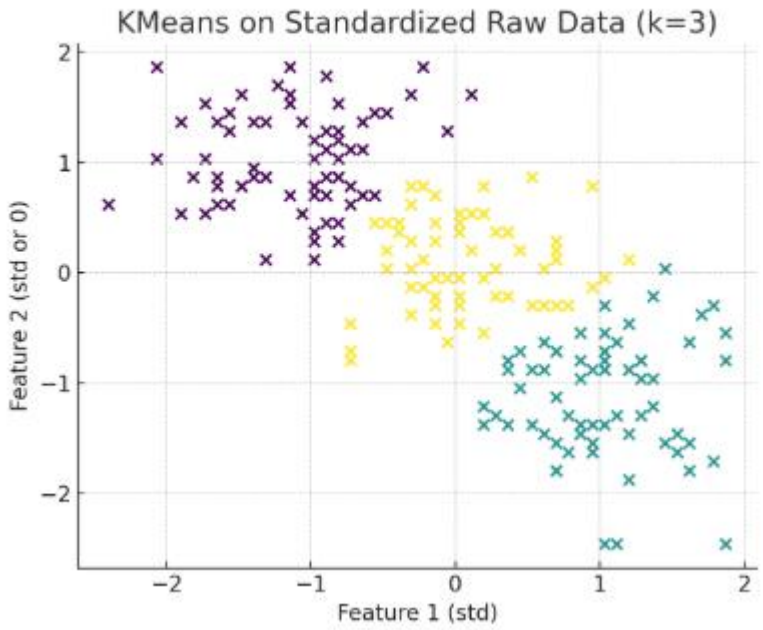
$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

| s(i) 範圍 | 意義 | 說明 |
|---|---|---|
| s(i) 接近 1 | 分得很好 | 與本群距離小、<br>與他群距離大 |
| s(i) 接近 0 | 邊界樣本 | 位於兩群之間 |
| s(i) < 0 | 分錯群 | 離他群更近 |

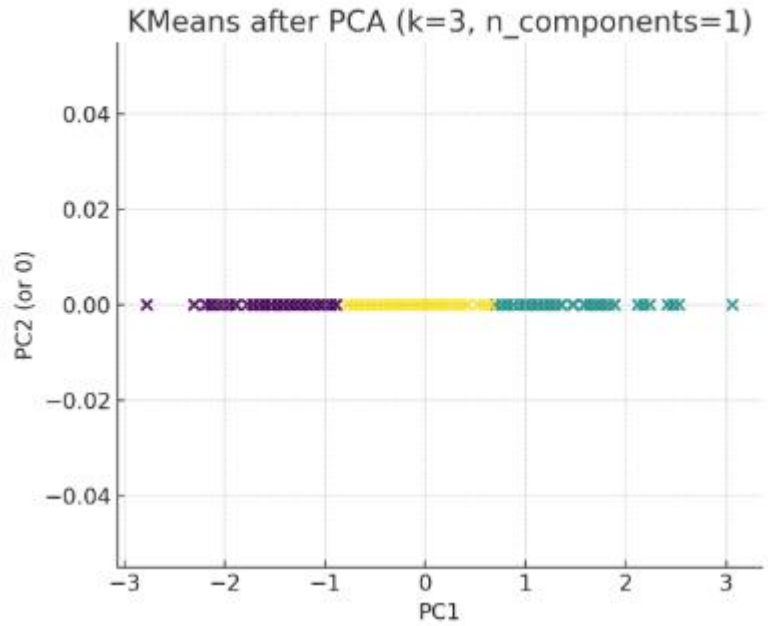
全部樣本的平均：
**(平均 silhouette score)**

$$\text{Silhouette score} = \frac{1}{n} \sum_{i} s(i)$$

KMeans On Standardized Raw Data (K=3)




KMeans After PCA (K=3, N_components=1)



# 作業： PCA 與 K-means 分群分析




使用 AI 協助（如 ChatGPT 或其他輔助工具），完成以下資料分析任務：
對 **students_200.csv** 進行 **PCA 降維**，並使用 **K-means (n=3)** 進行分群

**1. 原始資料分析**

對原始資料（未降維）使用 K-means (n=3) 分群
計算並記錄其 silhouette score

**2.PCA 降維分析**

使用 PCA 將資料降維（可嘗試不同維度，如 1、2、3 維），
找出 最適的降維維度（使分群效果最佳）
重新進行 K-means (n=3) 分群
計算降維後的 silhouette score

**一份 PDF 報告，內容包含：**

- 分析步驟與過程說明
- 使用 AI 工具協助的截圖
- 程式碼與輸出結果
- 降維前後的 silhouette score 比較